

Bitácora de la IA · Wilmercito (llama.cpp)

Defensa: prompts usados en OpenCode + respuestas/acciones + evidencia, paso a paso. Cobertura honesta: esta sesión es **verbatim** (cada prompt tal cual se escribió); el trabajo previo a esta sesión viene de handoffs y memoria (resumido, no verbatim).

Slices (un archivo por slice, en orden cronológico)

| # | Slice | Qué demuestra | | 01 | slice-01-rama-limpia.md | Crear rama, verificar dev, limpiar legacy V1 | | 02 | slice-02-infra-vm-db.md | SSH sin password, PostgreSQL en VM, backup/restore | | 03 | slice-03-llamacpp-gpu.md | Compilar llama.cpp CUDA, modelo Qwen, server con api-key | | 04 | slice-04-fase1-retrieval.md | Endpoints /ia/*, Chroma, calibración de umbral | | 05 | slice-05-burbuja-chat.md | Burbuja Wilmercito, burbuja invisible (CSS), burbuja visible | | 06 | slice-06-guardrails.md | Jailbreak que cuenta chistes · defensa en 3 capas | | 07 | slice-07-modelo-3b.md | 1.5B vs 3B medido, rechazo exacto | | 08 | slice-08-loop-aprendizaje.md | ·/· · Feedback IA · jefe promueve · Clona | | 09 | slice-09-panel-asistente.md | Pestaña Asistente, fuentes amigables, /conocimiento | | 10 | slice-10-todo-el-sistema.md | Usuarios, áreas, estadísticas SQL, BM25+RRF | | 11 | slice-11-mcp-poderes.md | MCP 18 tools, poderes con confirmación, usuario Wilmercito | | 12 | slice-12-humanidad.md | Nombre, hora, memoria, empatía, tarjetas, turnos, informes | | 13 | slice-13-finetuning.md | 3 noches, 5/30, diagnóstico + plan (resultado negativo honesto) | | 14 | slice-14-produccion.md | P0, backups, systemd, tests, credenciales, merge, deploy | | 15 | slice-15-revision.md | Revisión formal nativa: intento terminal honesto |

Cómo leer cada slice

Cada archivo tiene: **Objetivo** · **Prompts** (verbatim, con > quote) · **Respuesta/acciones del agente** · **Evidencia** (commits, comandos, salidas) · **Decisión/hallazgo**