

Slice 03 · llama.cpp en GPU (sin Ollama)

Objetivo

Motor LLM propio en el host GPU, sin Ollama (decisión del usuario: más puntos).

Prompts

1. ¿El docente acepta solo llama.cpp, o quiere Ollama funcionando + llama.cpp como plus? (...) R- Ollama debería de no existir si usas llama.cpp, en caso de no lograrlo con llama.cpp volvemos a intentar con ollama, pero no usemos nada de ollama. 2. ¿La demo final corre en la VM (...) o el Soporte se queda aquí y la VM solo da el RAG viejo? R- La demo final corre en la VM, en esta pc solo hardware y llama.cpp (...)

Respuesta / acciones del agente

- 1 Recon: RTX 2060 6 GB libre, qwen2.5:1.5b ya descargado en Ollama, llama-server inexistente, VM con 2ms.
- 2 `git clone llama.cpp + cmake -DGGML_CUDA=ON -DCMAKE_CUDA_ARCHITECTURES=75 (sm_75 = Turing/2060) + build (16 cores).`
- 3 GGUF qwen2.5-1.5b-instruct-q4_k_m.gguf (1.1 GB) desde HuggingFace.
- 4 Fallos intermedios reales: `--system-prompt-file` no existe en ese build (el system va por request, mejor diseño); puerto 8080 ocupado por coolify-proxy 8081 + regla ufw solo para la VM.
- 5 `systemctl stop + disable ollama` (binario conservado).
- 6 llama-server arriba: /health ok, 401 sin key, auth con `--api-key` verificada.
- 7 Pruebas de restricción con 1.5B: mundial · parafraseo (no exacto) ignoró las reglas contó un chiste. Falla registrada · motivó guardrails en backend (slice 06).

Evidencia

- `~/llama.cpp/build/bin/llama-server --version 0.5.0-dev`
- `nvidia-smi`: 1218 MiB con 1.5B; `~/modelos/wilmercito-system.txt`
- `~/run-llama.sh` (arranque sin `kill`, que se auto-mataba)

Decisión / hallazgo

- El 1.5B solo no sostiene restricciones · la restricción debe vivir en código, no en el prompt.