

Slice 04 · Fase 1 retrieval (la/* + Chroma)

Objetivo

Búsqueda semántica sobre atenciones con alucinación = 0 (mostrar tickets reales, sin generar texto).

Prompts

(decisiones previas: datos reales, burbuja en Django, nombre Wilmercito) Flujo de trabajo del agente: explorar `backend-fastapi/app` (routers, `Atencion`), crear `app/services/ia_retrieval.py` + `app/routers/ia.py`, registrar router en `main.py`.

Respuesta / acciones del agente

- 1 Impacto GitNexus previo (app no resuelto · riesgo LOW por inspección: solo agrega import + `include_router`).
- 2 Creados: `ia_retrieval.py` (lazy embeddings multilingües, Chroma persistente, `tolist()` obligatorio, indexado idempotente `atencion_<Id>`) y `ia.py` (`/buscar`, `/reindexar`, `/estado`, umbral 0.35 heredado).
- 3 Sincronizado a VM, indexado **2771/2771**.
- 4 Calibración real que rompió el umbral heredado: distancias L2 al cuadrado (1.2·11.6), no coseno: `normalize_embeddings=True` · coseno 0..2; medido buenos 0.06·0.42, mundial 0.61. **Umbral 0.5**.
- 5 Wipe + reindex limpio; `/ia/buscar` devuelve 3 tickets reales (ej: impresora · 0.238).

Evidencia

- Commits: 9dff9fb (docs/contratos), 8bd7be5 (fix django)
- POST `/api/ia/reindexar` · `{'nuevas': 2771, 'total': 2771}`
- Medición de distancias por query (impresora/internet/mundial/toner/cuentas)

Decisión / hallazgo

- Los umbrales no se heredan entre embeddings: se calibran con datos propios.
- Chroma query sin normalizar devuelve L2²; normalizado equivale a coseno.