

Slice 06 · Guardrails (el modelo contaba chistes)

Objetivo

Que Wilmercito rechace fuera-de-tema y jailbreaks aunque el modelo falle.

Prompts

(tras ver que el 1.5B contaba chistes ante "ignora las reglas") Implementación de ~~la~~ **ia/preguntar** con defensa en profundidad.

Respuesta / acciones del agente

- 1 Medición previa: mundial · parafraseo amable (no exacto); jailbreak · chiste completo.
- 2 Diseño en 3 capas (backend, no en el prompt):
 - **Capa 1** prefiltro regex jailbreak · rechazo exacto sin llamar al motor.
 - **Capa 2** system + Context/Question/Answer al motor.
 - **Capa 3** postfiltro: marcadores fuera-de-tema · rechazo exacto; distancia > umbral · sin dato.
- 3 Verificado e2e: jailbreak · Solo puedo responder . . . + rechazado: True.

Evidencia

- app/routers/ia.py: _JAILBREAK, _MARCAS_FUERA_DE_TEMA, RECHAZO_EXACTO, SIN_DATO
- Tests test_ia_unit.py (atraparon olvidá con tilde pasando el filtro)

Decisión / hallazgo

- Modelos chicos: la restricción vive en código. El prompt solo es la capa 2 de 3.