

Fine-tuning LoRA de Wilmercito (Qwen2.5-3B) · plan

Estado: PLANIFICADO (no ejecutado). GPU: RTX 2060 6 GB en server-mattias.

1. Por qué

El RAG actual razona sobre contexto recuperado, pero el modelo base no "sabe" el dominio: redacta con estilo genérico y a veces ignora el formato. Un LoRA sobretickets reales le enseña el vocabulario (categorías, áreas, medios), el formato de respuesta (breve, español, cita de fuente) y las restricciones (rechazo exacto).

2. Dataset (todo sale del sistema, sin etiquetado manual masivo)

| Fuente | Pares aprox. | Formato | |---|---|---| | Atenciones (Descripción · Solución) | 2771 | instrucción: problema + categoría/área; respuesta: solución KB curada + feedback promovido | ~10 y creciendo | pregunta · respuesta exacta || Rechazos sintéticos | ~40 | preguntas fuera de tema · rechazo exacto; jailbreaks · rechazo exacto |

Script: `scripts/ft/build_dataset.py` (ya implementado y verificado en VM: 2229 pares válidos desde DB real; ojo: ~500 descripciones duplicadas en tickets, el builder las filtra) +

`scripts/ft/validate_dataset.py`. Inspiración `patmakesapps/qwen-qlora-runpod-template` (datasets modulares, persona, validate/train/test/merge) y

`wazih-shourov/Qwen3-8B-Custom-Persona-LoRA` (identidad propia vía LoRA · como Wilmercito). Eval RAG: `ragas` (faithfulness, answer relevancy) · `docs/specs/turnos-gpu.md`.

3. Entrenamiento (Unsloth QLoRA, 6 GB VRAM)

- Base: `unsloth/Qwen2.5-3B-Instruct-bnb-4bit`. QLoRA `r=16`, `alpha=16`, `batch 2`, `gradient_accumulation 4`, `1.2 epochs`, `lr 2e-4`, `maxseq 2048`.
- Costo estimado: 2.4 h en la 2060. Correr de noche con llama-server detenido (la VRAM no alcanza para entrenar y servir a la vez).
- Entorno: `~/ft-wilmercito/` (fuera del repo; solo el dataset versionado entra a la rama si el docente lo pide, anonimizado).

4. Merge + GGUF + despliegue

- 1 `model.save_pretrained_gguf(..., quantization_method="q4_k_m") · ~/modelos/wilmercito-3b-q4_k_m.gguf`
- 2 Apuntar `~/run-llama.sh` al nuevo GGUF y reiniciar. Rollback: el GGUF base sigue ahí.
- 3 Re-correr el set de evaluación (§5): debe igualar o superar al base en todo.

5. Evaluación (antes de declarar victoria)

Set fijo `data/ft_eval.jsonl` (~30 casos: identidad, saludo, categorías, how-to, tickets reales, mundial, jailbreaks, estadísticas). Métricas: rechazo exacto, fuente correcta, distancia de retrieval, latencia. Criterio: 0 regresiones vs base.

6. Riesgos honestos

- **Catastrophic forgetting**: el LoRA puede empeorar español general · mitigado pocas epochs + eval de regresión.
- **Overfitting a tickets**: responde bien a lo visto, igual que RAG · por eso el RAG se queda; el LoRA mejora estilo y restricciones, no sustituye retrieval.

- **6 GB justos:** si OOM, bajar a Qwen2.5-1.5B o a batch 1.