

---

title: "Fase A · MCP server real de Soporte (FastMCP)" status: "approved" # draft | approved | rejected version: "1.0" priority: "alta" estimated\_effort: "2-3 sesiones" dependencies: ["rama dev\_llama.cpp", "llama-server :8081 en host", "VM upds con PG15"]

## Historia de usuario

**Como** técnico de soporte **quiero** pedirle a Wilmercito acciones con herramientas (buscar, crear borrador, estadísticas) **para** resolver atenciones sin salir del chat.

## Objetivo

Exponer el sistema como servidor MCP real (stdio + HTTP) con 12 tools, sin bypass de roles.

---

## Stack Tecnológico (OBLIGATORIO)

| Capa | Tecnología | Versión | Notas | | MCP server | FastMCP (Python) | v2.x | stdio + HTTP Streamable :8090 en VM | | Backend consumido | FastAPI existente | · | tools llaman a http://127.0.0.1:5012 | | Auth | JWT del técnico (passthrough) | · | cero bypass, s\_privileged se respeta | | Retrieval | Chroma + multilingual-MiniLM | · | reutiliza ia\_retrieval | | LLM cliente | llama-server Qwen2.5-3B | :8081 host | solo para redactar con contexto |

## Arquitectura

### Diagrama de componentes (textual)

```
[Burbuja/MCP client] --stdio/HTTP--> [mcp_soporte :8090]
--HTTP+JWT--> [FastAPI :5012]
      |
      +-- ia_tools (schemas)
      +-- PG15 + Chroma
```

### Mapa de archivos

```
# Archivos a crear:
backend-fastapi/app/mcp_soporte/__init__.py      # registro y app
FastMCP
backend-fastapi/app/mcp_soporte/server.py        # main stdio/HTTP
+ api-key
backend-fastapi/app/mcp_soporte/tools_atenciones.py #
buscar/get/crear-borrador/confirmar/actualizar/reclasificar
backend-fastapi/app/mcp_soporte/tools_sistema.py  # stats,
jerarquía, usuarios, horarios
backend-fastapi/app/mcp_soporte/tools_ia.py       #
preguntar/calificar/promover/evaluar (envuelven ia.py)
backend-fastapi/requirements.txt                 # +fastmcp
```

---

```
(modificar)
docs/specs/fase-a-mcp-server.md # esta spec
# Archivos a modificar: ninguno existente (solo suma).
```

## Contratos de Datos

### Tools (request / response)

```
# soporte_buscar_atenciones
{"texto": str, "top_k": int = 3}
# -> {"resultados": [{"id": "atencion_94", "descripcion": str,
"distancia": float}]}
# soporte_crear_borrador (NO guarda)
{"descripcion": str, "categoria": str, "area_solicitante": str,
...}
# -> {"preview": {...}, "requiere_confirm": True}
# soporte_confirmar_creacion (GUARDA; exige confirm:true + JWT
válido)
{"borrador": {...}, "confirm": True}
# -> {"id": int, "colaborador": "Wilmercito"}
# soporte_stats_tecnico
{"nombre": str} # matching por tokens normalizados
# -> {"display_name": str, "total": int, "mes": int,
"top_categorias": [...]}
```

### Reglas de Negocio

- 1 **RN-01:** Toda escritura exige `confirm:true` explícito del humano.
- 2 **RN-02:** Toda escritura lleva `colaborador_id` = Wilmercito (lookup por email); el autor es el dueño del JWT.
- 3 **RN-03:** Sin JWT válido · 401; sin privilegio en rutas de jefe · 403 (misno privileged).
- 4 **RN-04:** Lectura nunca inventa: sin evidencia · `sin_evidencia:true` (no texto generado).

### Flujo Principal · crear atención desde el chat

- 1 Técnico:"crea la atención: impresora B-05 no imprimè
- 2 `soporte_crear_borrador` · preview "¿confirmas{Sí}"
- 3 Técnico:"sí"
- 4 `soporte_confirmar_creacion{confirm:true}` con su JWT · POST /api/atenciones/batch
- 5 Respuesta: "Creada #3120 a tu nombre, colaborador Wilmercito"

### Flujo Alternativo · sin confirmación

- 1 Si `confirm` falta o es falso · 400"requiere\_confirm" (nada se guarda).

### Flujo de Error

| Condición                      | Respuesta  | Status | Mensaje                  |
|--------------------------------|------------|--------|--------------------------|
| Sin JWT                        | Auth Error | 401    | "Falta token Bearer"     |
| Técnico pide ruta de jefe      | Forbidden  | 403    | "Solo un jefe puede."    |
| Motor IA caído (solo tools IA) | Degraded   | 503    | "motor-ia-no-disponible" |

## Catálogo de Errores

```
| Código | HTTP | Condición | Mensaje visible | Log | -----|-----|-----|-----|-----| MCP-001 | 401 | sin  
JWT | "Falta token Bearer" | warn | | MCP-002 | 403 | sin privilegio | "Solo un jefe puede." | warn | | MCP-003 | 400 |  
escritura sin confirm | "requiere_confirm" | info | | MCP-004 | 503 | llama-server caído | "motor-ia-no-disponible" |  
error |
```

## Criterios de Aceptación (Gherkin)

```
Feature: MCP Soporte  
  Scenario: Crear atención con confirmación  
    Given JWT de técnico válido  
    When creo borrador y luego confirmo con confirm:true  
    Then la atención existe con mi autoría y colaborador Wilmercito  
  Scenario: Sin confirmación no guarda  
    Given un borrador válido  
    When confirmo sin confirm:true  
    Then 400 requiere_confirm y nada se crea  
  Scenario: Inspector lista tools  
    When abro el inspector MCP contra :8090  
    Then veo 12+ tools con schemas
```

## Mockups ASCII · panel Asistente (ya existe, solo sumar)

```
+-----+  
| Wilmercito · control |  
| [Docs: 2845] [Motor: ok] [Por curar: N] |  
| [Reindexar] [Curar conocimiento] [Ver tools MCP] |  
+-----+
```

## Definition of Done (DoD)

- 1 [x] Inspector MCP lista 12+ tools con schemas válidos (18 verificados via `list_tools`)
- 2 [x] Borrador · confirmar crea atención real con colaborador Wilmercito (e2e id 3768, limpiado)
- 3 [x] Sin confirm no se guarda (MCP-003 verificado: `requiere_confirm`)
- 4 [x] 401/403 con JWT ausente o rol insuficiente (passthrough, sin bypass)
- 5 [x] POST `/ia/evaluar` sigue 10/10 sin regresiones
- 6 [x] `gitnexus_impact(preguntar)` LOW; `wilmercito_vista` LOW
- 7 [x] Rama limpia, docs actualizadas

## Orden de Implementación

- 1 **Paso 1:** `mcp_soporte/` + `server stdio/HTTP ·server.py`
- 2 **Paso 2:** tools lectura (usan endpoints existentes) `tools_atenciones.py(R)`,  
`tools_sistema.py`
- 3 **Paso 3:** tools escritura con confirm `tools_atenciones.py(W)`
- 4 **Paso 4:** tools IA (envoltorios) `tools_ia.py`
- 5 **Paso 5:** e2e en VM + inspector + commit

## Lo que NO está en alcance (explícito)

- · Function-calling directo del 3B (no fiable; los intents llaman tools)
- · Escritura sin confirmación humana
- · Cambiar permisos/roles existentes