
title: "Turnos GPU + jobs nocturnos (serve de día, entrena de noche)"
status: "approved" # draft | approved | rejected version: "1.0" priority: "alta"
estimated_effort: "2 sesiones" dependencies: ["llama-server.service en host", "VM upds con PG15", "docs/fine-tuning-lora.md"]

Historia de usuario

Como jefe del equipo, **quiero** que la GPU sirva de día y mejore el modelo de noche **para** que Wilmercito aprenda solo sin interrumpir el servicio.

Objetivo

Ventana nocturna 01:00-05:00: jobs de mejora + entrenamiento; de día, inferencia.

Stack Tecnológico (OBLIGATORIO)

| Capa | Tecnología | Versión | Notas | GPU | RTX 2060 6 GB, CUDA 12.4 | host |
turnos por systemd timers || Serve (día 05:00-01:00) | llama-server build propio | :8081 | GGUF activo Dataset |
scripts/ft/build_dataset.py | rama | tickets + KB + feedback + rechazos || Train (noche) | Unsloth
QLoRA Qwen2.5-3B | ~/ft-wilmercito/ | r=16, batch 2, 1.2 epochs | Eval | POST /ia/evaluar + ragas
faithfulness | · | regresión = aborta despliegue | Orquestación | systemd timers host + VM | · | sin cron (no existe en host)
|

Arquitectura

Diagrama de componentes (textual)

```
[timer 01:00] --> stop llama-server --> [job: reindex] --> [job: evaluar+alerta]
--> [job: build_dataset] --> [job: train_qlora] --> [job: eval adapter]
--> [si pasa: merge+GGUF] -- [timer 05:00] --> start llama-server (nuevo GGUF)
```

Mapa de archivos

```
# Archivos a crear:
scripts/ft/build_dataset.py      # DB+KB+feedback ->
data/ft_train.jsonl (formato messages)
scripts/ft/validate_dataset.py  # JSONL válido, roles, duplicados,
balance de clases
scripts/ft/nightly.sh           # orquesta la ventana
(stop/jobs/start con lock)
docs/specs/turnos-gpu.md        # esta spec
# Infra (fuera de la rama, documentada):
/etc/systemd/system/ft-nightly.{service,timer} # host 01:00
/etc/systemd/system/llama-server.service       # ya existe; el
```

job lo para/arranca

Contratos de Datos

Dataset (data/ft_train.jsonl, formato messages)

```
{"messages": [{ "role": "system", "content": "<WILMERCITO_SYSTEM>" },
  { "role": "user", "content": "¿cuáles son las categorías?" },
  { "role": "assistant", "content": "Las 8 categorías." } ] }
```

Clases obligatorias: tickets (2771), kb (curada), feedback (promovido), rechazo (~40 sintéticos: mundial, jailbreaks), identidad (Wilmercito).

Job evaluar+alerta

```
# POST /ia/evaluar (jefe) -> { "n": 10, "con_fuente": 10, "filas": [...] }
# Alerta si: con_fuente < 9, o p95 (LogIA 24h) > 30000ms, o rechazos/hora > 5
# Destino alerta (v1): archivo ~/ft-wilmercito/ALERTAS.md (el jefe lo ve en /asistente)
```

Flujo Principal · noche estándar

- 1 01:00 timer para llama-server (API responde 503, documentado como degradado)
- 2 Reindex Chroma (cambios del día) `POST /api/ia/reindexar`
- 3 `/ia/evaluar` · si regresión, escribe ALERTAS.md **aborta** (no entrena sobre datos rotos)
- 4 `build_dataset.py` + `validate_dataset.py` (falla si JSONL inválido)
- 5 `train_qlora.py` (Unsloth, ~2.4 h)
- 6 Eval del adapter contra `data/ft_eval.jsonl`; si pasa · merge + GGUF `wilmercito-3b-AAAAMDD-q4_k_m.gguf`
- 7 05:00 arranca llama-server con el GGUF más nuevo que pasó eval (rollback = anterior)

Flujo Alternativo · sin datos nuevos

- 1 Si `build_dataset.py` genera 0 pares nuevos · se salta train (solo eval + alerta).

Flujo de Error

Condición	Respuesta	Acción
Eval con regresión	aborta noche	ALERTAS.md + mantiene GGUF actual
OOM en train	aborta	reintenta con batch 1 a la noche siguiente
05:00 y train sin terminar	mata train	arranca serve (servicio manda)

Catálogo de Errores

Código	Condición	Visible	Log
FT-001	dataset inválido	ALERTAS.md	error
FT-002	regresión en eval	ALERTAS.md + /asistente	error
FT-003	OOM	ALERTAS.md	error
FT-004	serve no arranca 05:00	systemd failed	error

Criterios de Aceptación (Gherkin)

Feature: Turnos GPU

Scenario: Noche normal sin datos nuevos

Given timer 01:00 dispara

When build_dataset da 0 pares nuevos

Then se salta train y serve arranca 05:00 con el mismo GGUF

Scenario: Regresión freno despliegue

Given evaluar con con_fuente < 9

When corre el job

Then aborta antes de train y escribe ALERTAS.md

Definition of Done (DoD)

- 1 ☐ build_dataset.py genera JSONL válido desde DB real (tickets+KB+feedback+rechazos)
- 2 ☐ validate_dataset.py rechaza JSONL roto (test con fixture mala)
- 3 ☐ Noche simulada de día (comando manual) corre stop-jobs-start sin errores
- 4 ☐ Timers instalados y documentados; rollback probado (GGUF anterior arranca)
- 5 ☐ Rama limpia

Orden de Implementación

- 1 **Paso 1:** build_dataset.py + validate_dataset.py ·scripts/ft/
- 2 **Paso 2:** nightly.sh + corrida manual diurna · host
- 3 **Paso 3:** timers + ALERTAS.md visible en /asistente · host + Django
- 4 **Paso 4:** train_qlora.py (Unsloth) primera noche real ~/ft-wilmercito/

Lo que NO está en alcance (explícito)

- · Entrenar de día (la VRAM no da para servir + entrenar)
- · Auto-despliegue sin pasar eval (siempre con gate)
- · Datasets con datos personales fuera del esquema (solo tickets/KB/feedback)