

DOCUMENTACION.md · Decisiones técnicas y arquitectura

1. Arquitectura

```
.. HOST server-mattias (GPU) .....
· llama.cpp GGML_CUDA (sm_75, RTX 2060 6 GB) ·
· qwen2.5-3b-instruct-q4_k_m.gguf (2.0 GB) ·
· llama-server :8081 (OpenAI-compatible, api-key; ufw solo VM) ·
.....
· Tailscale
.. VM upds (Debian 12, VirtualBox sobre host Windows del aula) ..
· PostgreSQL 15 :5432 (soporte / soporte_dev) ·
· backend-fastapi :5012 (endpoints /api/ia/*) ·
· frontend-django :8011 (burbuja Wilmercito) ·
· Chroma ./chroma_db (CPU) + reglas en código ·
.....
```

Flujo de pregunta: burbuja ·POST /wilmercito/ (Django, con JWT de sesión; el JWT nunca sale al navegador) ·
POST /api/ia/preguntar · intent exacto embedding + top-3 Chroma ·POST
:8081/v1/chat/completions · respuesta confuente.

Índice: 2886 documentos (319 prod + 2494 histórico + KB estática) + usuarios/áreas/feedback promovido).
Embeddings paraphrase-multilingual-MiniLM-L12-v2 **normalizados** (distancia coseno 0.2); umbral 0.5
calibrado con datos propios, sugerencia marcada "no verificado" hasta 0.9.

Topología de despliegue: la VM corre en **VirtualBox sobre un host Windows** (PC del aula); la GPU vive en otro
host Linux. Ambos se unen por **Tailscale**, por eso LLAMA_URL apunta a una IP 100.x aunque las máquinas no
compartan red física. Sin internet en el aula, el fallback es IP LAN o video de respaldo.

2. Decisiones

| Decisión | Por qué | -- | -- | **llama.cpp directo, sin Ollama** | Ollama embebe llama.cpp; el servidor directo da
control total (system por request, api-key, -ngl 99, temperatura 0.1) y es bonus track documentado | | Modelo
Qwen2.5-3B sobre 1.5B | Medido: el 1.5B parafraseaba el rechazo y contaba chistes ante jailbreak; el 3B devuelve
el rechazo exacto (2168 MiB VRAM, ~140 tok/s) | | Restricción en código, no en prompt | El modelo solo redacta; qué
responder/permitir/guardar lo decide código determinista testeado | Intents exactos antes que modelo | Saludos,
identidad, estadísticas, turnos, informes van por regex+SQL: rápido y 100 % fiable | Reranker cross-encoder OFF |
Medido: ordenaba la KB exacta 6ta/12; el bi-encoder calibrado gana en este dominio | | FT no desplegado | Eval
5/30 tres noches · el gate frenó el despliegue; base intacta en producción | Sin rebase pre-defensa | La revisión nativa
podía rebasar 49 commits sobre main; constancia en vez de forzarla |

3. Patrones aplicados

- **Service layer:** app/services/ (ia_retrieval, ia_tools, categorias, horarios, estados) separa dominio de transporte; los routers solo validan y delegan.
- **Guardrails en capas** (defensa en profundidad): prefiltro regex jailbreak · system + Context/Question/Answer · postfiltro de marcadores + umbral.
- **Strategy por intención_preguntar_impl** despacha a estrategias (_estadisticas, _informe por técnico/área/medio/categoría, turno_ahora, _comparativa_mes, poderes con chip de confirmación); el registro ia_tools.REGISTRO + ejecutar() despacha tools por nombre con schemas JSON.
- **RBAC + auditoría** escritura solo con confirmación explícita y roles_privileged, _puede_dashboard); cada pregunta se registra en LogIA (fuente, rechazo, ms); etiquetas

legibles por rol (fuente_label).

- **Loop de aprendizaje supervisado:** `FeedbackIA` · el jefe promueve `feedback_<id>` entra a Chroma. Nada aprende solo.

4. Contratos y errores

`POST /api/ia/buscar {texto, top_k} · {resultados[], sin_evidencia} (umbral 0.5).` `POST /api/ia/preguntar {pregunta, historial[.4]} · {respuesta, fuente, rechazado}.` `POST /api/ia/reindexar · {nuevas, total} (idempotente).` `GET /api/ia/estado,` `POST /api/ia/evaluar` (batería de 10, solo jefes), `GET /api/ia/resumen` (panel).

Errores: 503 `motor-ia-no-disponible` (motor caído) 200 `rechazado:true` + mensaje exacto (`jailbreak/fuera-de-tema`) · 200 `"No tengo ese dato disponible."` (sin evidencia).

5. Calidad y operación

Tests: 13 unitarios IA (intents, guardrails, labels; sin GPU/DB) + suites RISK (6, `review_risk.py`), SLICE (5, `review_slices.py`), FEEDBACK (6, `review_feedback.py`) y LENS (7, `review_lens.py`): 24 pruebas del pipeline de revisión local `/ia/evaluar` 10/10 en desarrollo y 9/10 en deploy (décimo caso: expectativa sobre-ajustada, respuesta válida). Operación: backups diarios 02:00 + réplica al host, restore probado (2771, `systemd` con `Restart=always` (resurrección verificada con `kill -9`), migraciones alembic hasta 0009_ia_observabilidad.

Referencia técnica completa `docs/integracion-llamacpp.md`.

Mapa de scripts (qué es cada archivo y si producción lo usa)

| Archivo | Para qué existe | Estado | `scripts/arrancar_produccion.sh` | Levanta API :5002 + web :8001 en desarrollo | Uso activo (dev) | `scripts/indexar_historico.py` | Indexado único de 2494 tickets históricos a Chroma | One-shot ya ejecutado; se conserva por trazabilidad | `scripts/ft/build_dataset.py` | Genera pares Q&A de entrenamiento desde tickets | Experimental (FT) | `scripts/ft/validate_dataset.py` | Valida el dataset antes de entrenar | Experimental (FT) | `scripts/ft/train_qlora.py` | Entrena adaptador QLoRA en GPU (3 noches, 5/30) | Experimental; el adapter **no** está en prod (gate) | `scripts/ft/test_adapter.py` | Evalúa el adapter (ft eval 30 casos) | Experimental (FT) | `scripts/ft/nightly.sh` | Orquesta dataset·train·test en una noche | Experimental (FT) |

Nada en `scripts/ft/` corre en producción: el modelo servido es el base Qwen2.5-3B Q4 sin adapter. Detalle del experimento: `docs/bitacora-ia/slice-13-finetuning.md`.