

DOCUMENTACION.md · Decisiones técnicas y arquitectura

1. Arquitectura

```
.. HOST server-mattias (GPU) .....
. llama.cpp GGML_CUDA (sm_75, RTX 2060 6 GB) .
. qwen2.5-3b-instruct-q4_k_m.gguf (2.0 GB) .
. llama-server :8081 (OpenAI-compatible, api-key; ufw solo VM) .
.....
. Tailscale
.. VM upds (Debian 12) .....
. PostgreSQL 15 :5432 (soporte / soporte_dev) .
. backend-fastapi :5012 (endpoints /api/ia/*) .
. frontend-django :8011 (burbuja Wilmercito) .
. Chroma ./chroma_db (CPU) + reglas en código .
.....
```

Flujo de pregunta: burbuja ·POST /wilmercito/ (Django, con JWT de sesión; el JWT nunca sale al navegador) ·
POST /api/ia/preguntar · intent exacto embedding + top-3 Chroma ·POST
:8081/v1/chat/completions · respuesta confuente.

Índice: 2886 documentos (319 prod + 2494 histórico + KB estática * + usuarios/áreas/feedback promovido).
Embeddings paraphrase-multilingual-MiniLM-L12-v2 **normalizados** (distancia coseno 0.2); umbral 0.5
calibrado con datos propios, sugerencia marcada "no verificado" hasta 0.9.

2. Decisiones

| Decisión | Por qué | -- | **llama.cpp directo, sin Ollama** | Ollama embebe llama.cpp; el servidor directo da control total (system por request, api-key, -ngl 99, temperatura 0.1) y es bonus track documentado | | Modelo Qwen2.5-3B sobre 1.5B | Medido: el 1.5B parafraseaba el rechazo y contaba chistes ante jailbreak; el 3B devuelve el rechazo exacto (2168 MiB VRAM, ~140 tok/s) | | Restricción en código, no en prompt | El modelo solo redacta; qué responder/permitir/guardar lo decide código determinista testeado | Intents exactos antes que modelo | Saludos, identidad, estadísticas, turnos, informes van por regex+SQL: rápido y 100 % fiable | Reranker cross-encoder OFF | Medido: ordenaba la KB exacta 6ta/12; el bi-encoder calibrado gana en este dominio | | FT no desplegado | Eval 5/30 tres noches · el gate frenó el despliegue; base intacta en producción | Sin rebase pre-defensa | La revisión nativa pedía rebasar 49 commits sobre main; constancia en vez de forzarla |

3. Patrones aplicados

- **Service layer:** app/services/(ia_retrieval, ia_tools, categorias, horarios, estados) separa dominio de transporte; los routers solo validan y delegan.
- **Guardrails en capas** (defensa en profundidad): prefiltro regex jailbreak · system + Context/Question/Answer · postfiltro de marcadores + umbral.
- **Strategy por intención** preguntar_impl despacha a estrategias (_estadisticas, _informe por técnico/área/medio/categoría turno_ahora, _comparativa_mes, poderes con chip de confirmación); el registro ia_tools.REGISTRO + ejecutar() despacha tools por nombre con schemas JSON.
- **RBAC + auditoría** escritura solo con confirmación explícita y roles_privileged, _puede_dashboard); cada pregunta se registra en LogIA (fuente, rechazo, ms); etiquetas legibles por rol (fuente_label).
- **Loop de aprendizaje supervisado:** FeedbackIA · el jefe promueve feedback_<id> entra a Chroma. Nada aprende solo.

4. Contratos y errores

POST /api/ia/buscar {texto, top_k} · {resultados[], sin_evidencia} (umbral 0.5). POST /api/ia/preguntar {pregunta, historial[.4]} · {respuesta, fuente, rechazado}. POST /api/ia/reindexar · {nuevas, total} (idempotente). GET /api/ia/estado, POST /api/ia/evaluar (batería de 10, solo jefes) GET /api/ia/resumen (panel).

Errores: 503 motor-ia-no-disponible (motor caído) 200 rechazado:true + mensaje exacto (jailbreak/fuera-de-tema) · 200 "No tengo ese dato disponible." (sin evidencia).

5. Calidad y operación

Tests: 13 unitarios IA (intents, guardrails, labels; sin GPU/DB) + suites RISK (6, review_risk.py) y SLICE (5, review_slices.py); /ia/evaluar 10/10 en desarrollo y 9/10 en deploy (décimo caso: expectativa sobre-ajustada, respuesta válida). Operación: backups diarios 02:00 + réplica al host, restore probado (2771, systemd con Restart=always (resurrección verificada con kill -9), migraciones alembic hasta 0009_ia_observabilidad.

Referencia técnica completa docs/integracion-llamacpp.md.